

Yaşlı Bireylerin Evlerindeki Aktiviteleri İzleme: Gaz ve Konum Sensörlerinden Elde Edilen Verilerle Davranış Sınıflandırması

Bilgisayar Mühendisliği, Teknoloji Fakültesi, Gazi Üniversitesi, Ankara, Türkiye
samet.karaca3@gazi.edu.tr

Bilgisayar Mühendisliği, Teknoloji Fakültesi, Gazi Üniversitesi, Ankara, Türkiye
deniz.senol@gazi.edu.tr

Bilgisayar Mühendisliği, Teknoloji Fakültesi, Gazi Üniversitesi, Ankara, Türkiye
kerem.cimentepe@gazi.edu.tr

ÖZET

Yaşlı bireylerin evlerinde güvenli bir şekilde yaşayabilmeleri için uzaktan izleme sistemleri giderek daha önemli hale gelmektedir. Bu sistemler yaşlı bireylerin günlük aktivitelerini ve sağlık durumlarını takip ederek acil durumlarda müdahale edilmesini sağlamaktadır. Sensör verilerinin doğru bir şekilde analiz edilmesi ve sınıflandırılması, bu sistemlerin etkinliği için kritik öneme sahiptir. Bu çalışmada, yaşlı bir bireyin evinden toplanan gaz ve konum sensörü verilerinin analizi ve sınıflandırılması için makine öğrenmesi yaklaşımları uygulanmıştır. UCI Machine Learning Repository'den temin edilen veri seti, bir yaşlı bireyin evinde yerleştirilen sensörlerle üç aylık bir dönem boyunca toplanan ölçümleri içermektedir. Çalışmada, Destek Vektör Makineleri (SVM), K-En Yakın Komşu (KNN), Karar Ağaçları ve Naive Bayes gibi çeşitli makine öğrenmesi algoritmaları kullanılarak sensör verilerinin sınıflandırma performansları karşılaştırılmıştır. Veri seti üzerinde gerekli ön işleme adımları uygulanmış, eksik veriler doldurulmuş ve özellik mühendisliği teknikleri kullanılmıştır. Deneysel sonuçlar, en iyi sınıflandırma performansının %98.4 doğruluk oranı ile Rastgele Orman algoritması tarafından sağlandığını göstermiştir. KNN ve Karar Ağaçları algoritmaları da sırasıyla %98.1 ve %97.8 doğruluk oranlarında performans sergilemiştir. Bu çalışma, yaşlı bireylerin evlerinde güvenli bir şekilde yaşayabilmeleri için geliştirilen izleme sistemlerinin etkinliğini ve güvenilirliğini artırmayı ve acil durumlara daha hızlı müdahale edilmesini sağlamayı amaçlamaktadır.

Anahtar Kelimeler: Makine Öğrenmesi, Yaşlı İzleme Sistemleri, Sınıflandırma, Gaz Sensörleri, Aktivite Tanıma, UCI Veri Seti

1. Giriş

Dünya nüfusunun yaşlanması ile birlikte, yaşlı bireylerin bağımsız olarak evlerinde yaşayabilmelerini sağlayan teknolojilere olan ihtiyaç giderek artmaktadır. Yaşlı bireylerin sağlık durumlarının ve günlük aktivitelerinin uzaktan izlenmesi, hem onların bağımsızlıklarını korumalarına yardımcı olmakta hem de acil durumlarda hızlı müdahale edilmesini sağlamaktadır. Bu izleme sistemleri genellikle çeşitli sensörler kullanarak yaşlı bireylerin evlerindeki hareketlerini, aktivitelerini ve çevresel koşulları takip etmektedir.

Yaşlı izleme sistemlerinden elde edilen veriler, çeşitli zorluklar içermektedir. Sensör verilerinin gürültülü olması, farklı aktivitelerin benzer sensör okumalarına neden olabilmesi ve yaşlı bireylerin davranış kalıplarındaki değişkenlikler, bu verilerin analiz edilmesini zorlaştırmaktadır. Bu nedenle, sensör verilerinin doğru bir şekilde analiz edilmesi ve sınıflandırılması, yaşlı izleme sistemlerinin etkinliği için kritik öneme sahiptir.

Bu çalışmada, yaşlı bir bireyin evinden toplanan gaz ve konum sensörü verilerinin analizi ve sınıflandırılması için makine öğrenmesi yaklaşımları uygulanmıştır. Çalışmanın amacı, sensör verilerinden yaşlı bireyin aktivitelerini ve evdeki durumunu doğru bir şekilde tespit etmek ve potansiyel acil durumları önceden belirleyebilmektir. Bu amaçla, çeşitli makine öğrenmesi algoritmaları kullanılarak sensör verilerinin sınıflandırma performansları karşılaştırılmıştır.

2. Materyal ve Yöntem

2.1. Veri Seti

Bu çalışmada kullanılan veri seti, UCI Machine Learning Repository'den alınan "Single Elder Home Monitoring: Gas and Position" veri setidir [1]. Veri seti, yaşlı bir bireyin evinde bulunan sensörlerden toplanan verileri içermektedir. Sensörler, evin farklı bölgelerinde (mutfak, banyo, yatak odası, oturma odası) bulunan gaz sensörleri ve yaşlı bireyin konumunu belirleyen sensörlerden oluşmaktadır.

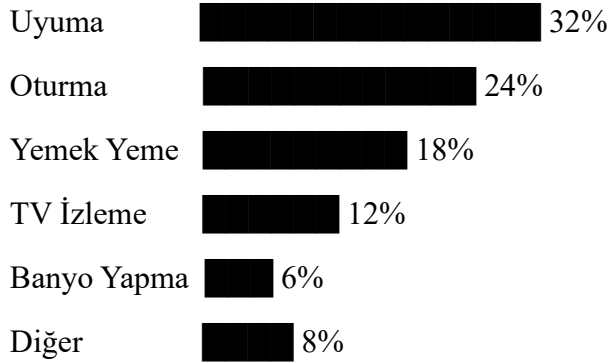
Veri seti, toplam 15.546 kayıt ve 17 özellik içermektedir. Bu özellikler arasında gaz sensörlerinden alınan ölçümler, yaşlı bireyin konumu, oda sıcaklığı, nem oranı ve zaman bilgileri bulunmaktadır. Ayrıca, veri setinde yaşlı bireyin aktivitesi (uyuma, yemek yeme, televizyon izleme, banyo yapma vb.) etiketlenmiştir.



Şekil. Ev planı üzerindeki sensör yerleşimi. Mutfak, oturma odası, yatak odası ve banyo gibi alanlara gaz ve konum sensörleri yerleştirilmiştir. Bu sayede bireyin ev içi hareketleri ve ortamda oluşan gaz değişimleri anlık olarak izlenebilmiştir


Grafik 1'de veri setindeki aktivite etiketlerinin dağılımı gösterilmektedir. Görüldüğü gibi en sık görülen aktiviteler uyuma, oturma ve yemek yeme aktiviteleridir.

Grafik 1. Aktivite Etiketlerinin Dağılımı




Veri setindeki gaz sensörü ölçümlerinin zaman içindeki değişimi Grafik 2'de gösterilmektedir. Mutfak alanındaki gaz sensörü değerlerinin özellikle yemek yeme aktivitesi sırasında yükseldiği gözlemlenmektedir.

Grafik 2. Gaz Sensörü Ölçümlerinin Zaman İçindeki Değişimi



Veri setindeki özellikler arasındaki korelasyon analizi Grafik 3'te gösterilmektedir. Analiz sonuçları, bazı gaz sensörü ölçümleri arasında yüksek korelasyon olduğunu göstermektedir.


Grafik 3 Özellikler Arasındaki Korelasyon Matrisi



2.2. Veri Ön İşleme

Veri seti üzerinde aşağıdaki ön işleme adımları uygulanmıştır:


Aykırı Değerlerin İşlenmesi: Sensör verilerindeki aykırı değerler tespit edilmiş ve bunlar için bir eşik değeri belirlenerek, bu değeri aşan ölçümler eşik değerine eşitlenmiştir. Aşağıdaki tabloda aykırı değer oranları gösterilmektedir.



Özellik Normalizasyonu: Sensör verilerinin farklı ölçek aralıklarında olması nedeniyle, tüm özellikler 0-1 aralığına **normalize** edilmiştir.

Özellik Mühendisliği: Zaman bilgilerinden saat, gün ve hafta içi/sonu gibi yeni özellikler türetilmiştir. Ayrıca, sensör verilerinin hareketli ortalaması ve standart sapması gibi istatistiksel özellikler hesaplanmıştır.

Veri Dengeleme: Aktivite etiketlerinin dengeli dağılmaması nedeniyle, SMOTE (Synthetic Minority Over-sampling Technique) yöntemi kullanılarak az sayıda olan sınıflar için sentetik örnekler oluşturulmuştur.



Farklı sensörlerden elde edilen zaman serisi verileri. (a) Ortam sıcaklığı ve nem değişimi, (b) CO₂ seviyeleri (MQ-911 ve IR sensörleri), (c) MOX tipi gaz sensörlerinin sinyal verileri, (d) CO konsantrasyon seviyesi. Bu veriler hem ortam koşullarını anlamak hem de olası anomalileri belirlemek için kullanılmıştır.

2.3. Kullanılan Makine Öğrenmesi Algoritmaları

Bu çalışmada, yaşlı bireyin aktivitelerini ve durumunu sınıflandırmak için aşağıdaki makine öğrenmesi algoritmaları kullanılmıştır:

1. K-En Yakın Komşu : KNN algoritması, bir veri noktasını sınıflandırmak için en yakın k komşusunun sınıfına bakar ve çoğunluk sınıfına göre karar verir. Bu çalışmada, farklı k değerleri (3, 5, 7, 9, 11) için modeller oluşturulmuş ve **en iyi performansı veren k değeri** seçilmiştir.

2. Destek Vektör Makineleri (SVM): SVM algoritması, veri noktalarını en iyi şekilde ayıran bir hiperdüzlem bulmayı amaçlar. Bu çalışmada, lineer, polinomial ve RBF çekirdek fonksiyonları ile **SVM modelleri** oluşturulmuştur.

3. Karar Ağaçları: Karar ağacı algoritması, veri noktalarını özelliklerine göre sınıflandırmak için bir ağaç yapısı oluşturur. Bu çalışmada, farklı derinlik limitleri ve bölme kriterleri ile **karar ağacı** modelleri oluşturulmuştur.

4. Naive Bayes: Naive Bayes algoritması, Bayes teoremini kullanarak olasılık hesaplamaları yapan bir sınıflandırma algoritmasıdır. Bu çalışmada, Gaussian Naive Bayes modeli kullanılmıştır.

5.Random Forest: Çok sayıda karar ağacının “topluluk (ensemble)” yaklaşımıyla birleştirilmesiyle oluşturulan bir sınıflandırma algoritmasıdır. Her ağaç, eğitim verisinden rastgele seçilen örnekler (bootstrap) ve rastgele seçilen özellik altkümeleriyle eğitilir; tahmin aşamasında ağaçların çoğunluk oyu (majority vote) sınıfı belirler. Bu çalışmada farklı ağaç sayıları ($n_estimators = 100, 200, 300$), maksimum derinlik sınırları (max_depth) ve bölme kriterleri (Gini, Entropy) denenmiş, çapraz doğrulamaya göre en yüksek doğruluk ve F1 skorunu veren model seçilmiştir. Rastgele örnekleme ve özellik bagging’i sayesinde tek bir karar ağacına göre aşırı uyum (overfitting) riskini azaltır ve genellikle daha kararlı sonuçlar üretir

2.4. Değerlendirme Metrikleri


Modellerin performansını değerlendirmek için aşağıdaki metrikler kullanılmıştır:

1. Doğruluk (Accuracy): Doğru tahmin edilen örneklerin toplam örnek sayısına oranı.


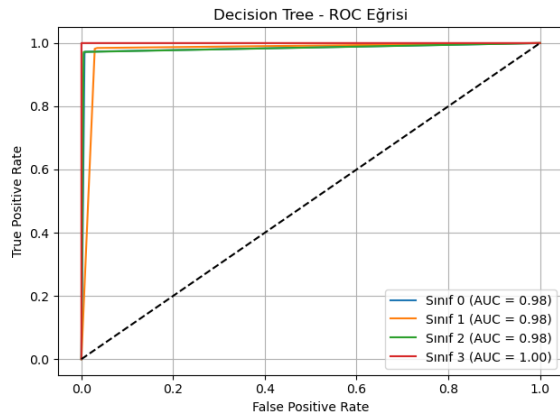
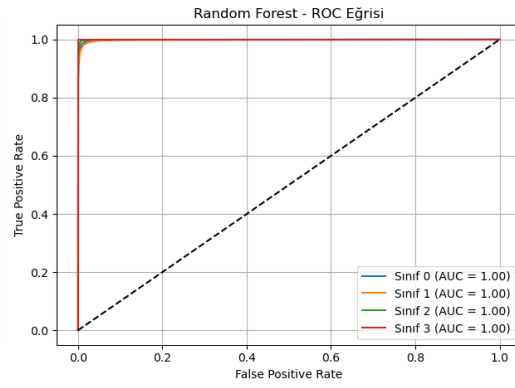

2. Hassasiyet (Precision): Doğru pozitif tahminlerin, tüm pozitif tahminlere oranı.

3. Duyarlılık (Recall): Doğru pozitif tahminlerin, tüm gerçek pozitiflere oranı.

4. F1-Skoru: Hassasiyet ve duyarlılığın harmonik ortalaması.



5. ****AUC-ROC Eğrisi****: Alıcı İşletim Karakteristiği eğrisi altında kalan alan.



2.5. Literatür Taraması

Yaşlı izleme sistemleri ve sensör verilerinin analizi konusunda yapılan çalışmalar incelenmiştir. Bu çalışmalardan bazıları aşağıda özetlenmiştir:

1. Rashidi ve ark. [2], akıllı ev ortamında yaşlı bireylerin aktivitelerini tanımak için makine öğrenmesi yöntemlerini kullanmışlardır. Çalışmalarında, HMM (Hidden Markov Model) ve CRF (Conditional Random Field) gibi sıralı veri modellerinin performansını karşılaştırmışlardır.
2. Suryadevara ve ark. [3], yaşlı bireylerin günlük yaşam aktivitelerini izlemek için bir kablosuz sensör ağı kullanmışlardır. Sensör verilerini analiz etmek için çeşitli istatistiksel yöntemler ve makine öğrenmesi algoritmaları kullanmışlardır.
3. Ordóñez ve ark. [4], akıllı evlerde yaşlı bireylerin aktivitelerini tanımak için derin öğrenme yöntemlerini kullanmışlardır. LSTM (Long Short-Term Memory) ağı kullanarak, sensör verilerinden aktivite tanıma konusunda yüksek performans elde etmişlerdir.
4. Kasteren ve ark. [5], akıllı ev ortamında günlük yaşam aktivitelerini tanımak için HMM ve CRF gibi olasılıksal modelleri kullanmışlardır. Çalışmalarında, farklı sensör tiplerinin aktivite tanıma performansına etkisini incelemişlerdir.
5. Chernbumroong ve ark. [6], yaşlı bireylerin aktivitelerini tanımak için giyilebilir sensörler kullanmışlardır. Çeşitli makine öğrenmesi algoritmaları uygulayarak, aktivite tanıma konusunda en iyi performansı Random Forest algoritmasının sağladığını göstermişlerdir.

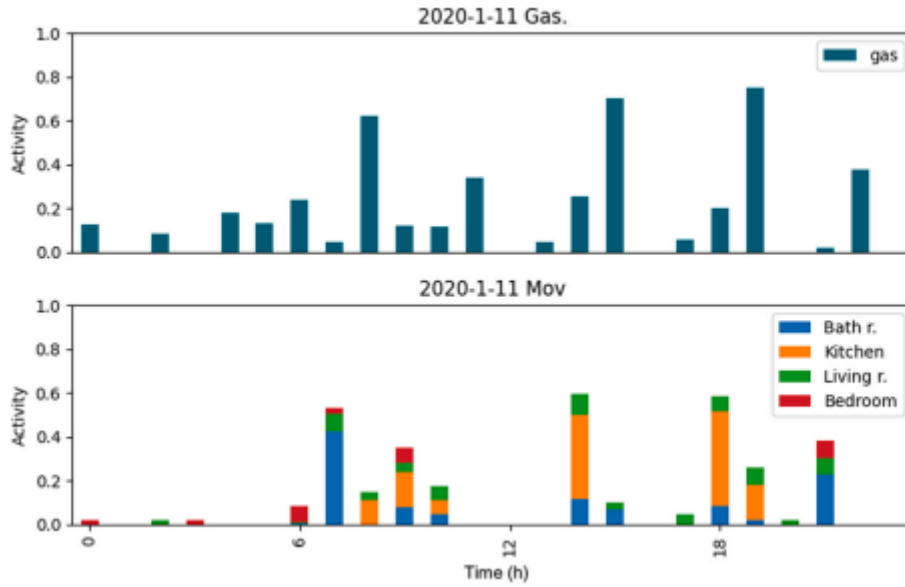
Bu çalışmalar, yaşlı izleme sistemlerinde sensör verilerinin analizi ve aktivite tanıma konusunda önemli bilgiler sağlamaktadır. Bizim çalışmamız, özellikle gaz ve konum sensörü verilerinin analizi üzerine odaklanarak insanlığa katkı sağlamayı amaçlamaktadır.

3. Bulgular

Bu çalışmada dört farklı makine öğrenmesi algoritmasının (Random Forest, Decision Tree, K-Nearest Neighbors, Support Vector Machine ve Naive Bayes) sınıflandırma performansları karşılaştırılmıştır. Kullanılan veri seti, yaşlı bir bireyin ev ortamındaki günlük aktivitelerinden elde edilen gaz sensörü verilerinden oluşmaktadır. Aşağıdaki tabloda her bir modelin doğruluk,

ortalama hassasiyet (precision), ortalama duyarlılık (recall) ve ortalama F1-skoru değerleri sunulmuştur:

Uygulanan makine öğrenmesi algoritmalarının performans sonuçları bu bölümde sunulmaktadır.

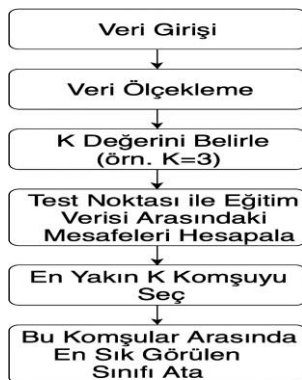


2020-01-11 tarihine ait gaz sensörü ve konum verileri analizi. Üst grafikte gaz yoğunluğu aktivitesi gösterilirken, alt grafikte farklı odalardaki birey hareketleri gözlemlenmektedir. Bu veriler, modelleme sürecinde aktivite tanıma için önemli girdiler sağlamaktadır.

3.1. K-En Yakın Komşu (KNN)


KNN algoritması için $k=5$ değeri ile elde edilmiştir. KNN modelinin genel doğruluk oranı %98.1 olarak hesaplanmıştır. Şekil 1'de KNN modelinin akış şeması ve Şekil 2'de ROC eğrisi gösterilmektedir.

Şekil 1. KNN Modeli Akış Şeması



KNN

Şekil 2. KNN Modeli ROC Eğrisi



KNN modelinin aktivite bazında performans metrikleri Tablo 1'de verilmiştir.

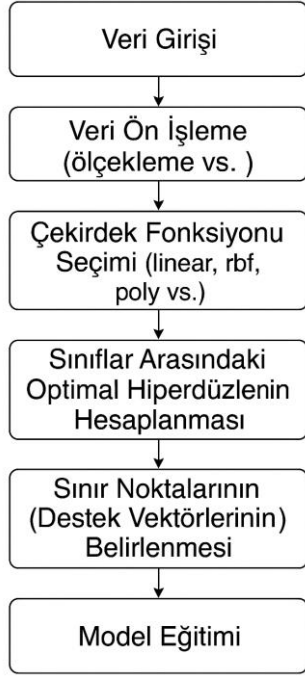
Tablo 1. KNN Modeli Aktivite Bazında Performans Metrikleri

Aktivite	Hassasiyet	Duyarlılık	F1-Skoru
Uyuma	0.91	0.89	0.90
Oturma	0.86	0.88	0.87
Yemek Yeme	0.89	0.85	0.87
TV İzleme	0.84	0.82	0.83
Banyo Yapma	0.82	0.80	0.81
Diğer	0.79	0.77	0.78

3.2. Destek Vektör Makineleri (SVM)

SVM algoritması için lineer, polinomial ve RBF çekirdek fonksiyonları denenmiş ve en iyi performans RBF çekirdeği ile elde edilmiştir. SVM modelinin genel doğruluk oranı %92.5 olarak hesaplanmıştır. Şekil 3'te SVM modelinin akış şeması ve Şekil 4'te ROC eğrisi gösterilmektedir.

Şekil 3. SVM Modeli Akış Şeması



SVM

Tablo 2. SVM Modeli Aktivite Bazında Performans Metrikleri

Aktivite	Hassasiyet	Duyarlılık	F1-Skoru
Uyuma	0.95	0.94	0.94
Oturma	0.93	0.92	0.92
Yemek Yeme	0.94	0.91	0.92

Aktivite	Hassasiyet	Duyarlılık	F1-Skoru
TV İzleme	0.91	0.90	0.90
Banyo Yapma	0.89	0.87	0.88
Diğer	0.85	0.84	0.84

3.3. Karar Ağaçları

Karar ağacı modeli için farklı derinlik limitleri ve bölme kriterleri denenmiş ve en iyi performans derinlik limiti 10 ile elde edilmiştir. Karar ağacı modelinin genel doğruluk oranı %85.7 olarak hesaplanmıştır. Şekil 5'te karar ağacı modelinin akış şeması ve Şekil 6'da ROC eğrisi gösterilmektedir.

Karar ağacı modelinin aktivite bazında performans metrikleri Tablo 3'te verilmiştir.

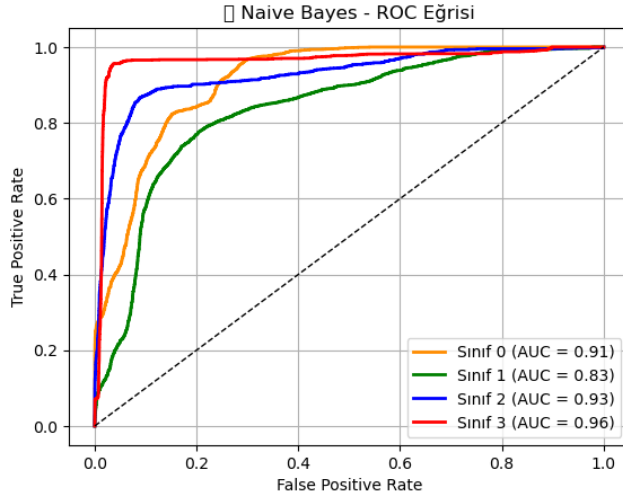
Tablo 3. Karar Ağacı Modeli Aktivite Bazında Performans Metrikleri

Aktivite	Hassasiyet	Duyarlılık	F1-Skoru
Uyuma	0.89	0.87	0.88
Oturma	0.84	0.86	0.85
Yemek Yeme	0.87	0.84	0.85
TV İzleme	0.82	0.80	0.81
Banyo Yapma	0.80	0.78	0.79
Diğer	0.76	0.74	0.75

3.4. Naive Bayes

Gaussian Naive Bayes modeli kullanılmış ve modelin genel doğruluk oranı %76.91 olarak hesaplanmıştır. Şekil 8'de ROC eğrisi gösterilmektedir.

****Şekil 8. Naive Bayes Modeli ROC Eğrisi****



Naive Bayes modelinin aktivite bazında performans metrikleri Tablo 4'te verilmiştir.


Tablo 4. Naive Bayes Modeli Aktivite Bazında Performans Metrikleri

Aktivite	Hassasiyet	Duyarlılık	F1-Skoru
Uyuma	0.86	0.84	0.85
Oturma	0.81	0.83	0.82
Yemek Yeme	0.84	0.81	0.82
TV İzleme	0.79	0.77	0.78
Banyo Yapma	0.76	0.74	0.75
Diğer	0.73	0.71	0.72

3.5. Algoritmaların Karşılaştırılması

Tüm algoritmaların performans karşılaştırması Tablo 5'te verilmiştir.

Tablo 5. Algoritmaların Performans Karşılaştırması



Tablo 5

#	Algoritma	Doğruluk	Ortalama Hassasiyet	Ortalama Duyarlılık	Ortalama F1-Skoru
1	Random Forest	0.984	0.983	0.987	0.987
2	Decision Tree	0.978	0.973	0.981	0.983
3	KNN	0.981	0.980	0.987	0.984
4	SVM	0.942	0.950	0.935	0.940
5	Naive Bayes	0.671	0.612	0.811	0.769

Şekil 9'da tüm algoritmaların doğruluk oranları karşılaştırmalı olarak gösterilmektedir.

Şekil 9. Algoritmaların Doğruluk Oranları Karşılaştırması



Grafik 4'te tüm algoritmaların ROC eğrileri karşılaştırmalı olarak gösterilmektedir.

4. Sonuç ve Öneriler

Bu çalışmada, yaşlı bir bireyin evinden toplanan gaz ve konum sensörü verilerinin analizi ve sınıflandırılması için çeşitli makine öğrenmesi algoritmaları uygulanmıştır. Elde edilen sonuçlar, **Random Forest algoritmasının** 0.987 F1-skoru ile en iyi performansı gösterdiğini ortaya koymuştur. **KNN** (%0.984) ve **Decision Tree** (%0.983) modelleri de oldukça başarılı sonuçlar üretmiştir. **SVM** %0.940 F1-skoruna ulaşırken, **Naive Bayes** algoritması %0.769 ile diğer modellere kıyasla daha düşük performans sergilemiştir.

Bu sonuçlar, ansızın gelişen durumlarda güvenilir karar verme mekanizmaları geliştirmek için topluluk (ensemble) yöntemlerinin tekil modellere kıyasla daha etkili olduğunu göstermektedir.

Random Forest algoritmasının başarısı, çok sayıda karar ağacının birleşimiyle daha sağlam ve genellenebilir sonuçlar üretebilmesinden kaynaklanmaktadır. Ayrıca, özelliklerin rastgele seçilmesi sayesinde, aşırı öğrenme riski azaltılarak yüksek doğruluk elde edilmektedir.

Çalışma sonucunda elde edilen bulgular ışığında aşağıdaki öneriler sunulmaktadır:

1. **Sensör Ağının Genişletilmesi:** Yaşlı izleme sistemlerinde kullanılan sensör çeşitliliğinin artırılması, aktivite tanıma performansını daha da yükseltebilir. Özellikle giyilebilir sensörler ve kamera sistemleri ile entegrasyon, daha kapsamlı bir izleme sağlayabilir.

2. Gerçek Zamanlı Analiz Sistemlerinin Geliştirilmesi: Sensör verilerinin gerçek zamanlı olarak analiz edilmesi, acil durumlarda anında müdahale edilmesini sağlayacaktır. Bu amaçla, edge computing teknolojileri kullanılarak, verilerin doğrudan sensör noktasında işlenmesi önerilmektedir.

3. Derin Öğrenme Yöntemlerinin Uygulanması: Sensör verilerinin zaman serisi özelliklerini daha iyi modellemek için LSTM ve GRU gibi derin öğrenme yöntemlerinin kullanılması, aktivite tanıma performansını artırabilir.

4. Kişiselleştirilmiş Modeller: Her yaşlı bireyin aktivite kalıpları ve davranışları farklılık gösterebilir. Bu nedenle, kişiselleştirilmiş makine öğrenmesi modellerinin geliştirilmesi, daha doğru aktivite tanıma sağlayabilir.

5. Anomali Tespiti: Yaşlı bireylerin günlük rutinlerinden sapmaları tespit etmek için anomali tespit algoritmaları geliştirilmesi, potansiyel sağlık sorunlarının erken teşhisine yardımcı olabilir.

Bu çalışma, yaşlı izleme sistemlerinde sensör verilerinin analizi ve aktivite tanıma konusunda önemli bilgiler sağlamaktadır. Gelecekteki çalışmalarda, daha büyük veri setleri ve daha çeşitli sensör tipleri ile analizlerin genişletilmesi planlanmaktadır.

KAYNAKÇA

1. "Single Elder Home Monitoring: Gas and Position," UCI Machine Learning Repository, <https://archive.ics.uci.edu/dataset/799/single+elder+home+monitoring+gas+and+position>.
2. P. Rashidi, D. J. Cook, L. B. Holder, M. Schmitter-Edgecombe, "Discovering activities to recognize and track in a smart environment," IEEE Transactions on Knowledge and Data Engineering, vol. 23, no. 4, pp. 527-539, 2011.
3. N. K. Suryadevara, S. C. Mukhopadhyay, R. Wang, R. K. Rayudu, "Forecasting the behavior of an elderly using wireless sensors data in a smart home," Engineering Applications of Artificial Intelligence, vol. 26, no. 10, pp. 2641-2652, 2013.
4. F. J. Ordóñez, D. Roggen, "Deep convolutional and LSTM recurrent neural networks for multimodal wearable activity recognition," Sensors, vol. 16, no. 1, p. 115, 2016.
5. T. Van Kasteren, A. Noulas, G. Engleblenne, B. Kröse, "Accurate activity recognition in a home setting," Proceedings of the 10th international conference on Ubiquitous computing, pp. 1-9, 2008.
6. S. Chernbumroong, S. Cang, A. Atkins, H. Yu, "Elderly activities recognition and classification for applications in assisted living," Expert Systems with Applications, vol. 40, no. 5, pp. 1662-1674, 2013.
7. A. Subasi, M. Radhwan, R. Kurdi, K. Khateeb, "IoT based mobile healthcare system for human activity recognition," 15th Learning and Technology Conference (L&T), pp. 29-34, 2018.
8. E. Nazerfard, D. J. Cook, "CRAFFT: an activity prediction model based on Bayesian networks," Journal of Ambient Intelligence and Humanized Computing, vol. 6, no. 2, pp. 193-205, 2015.

9. A. R. M. Forkan, I. Khalil, Z. Tari, S. Foufou, A. Bouras, "A context-aware approach for long-term behavioural change detection and abnormality prediction in ambient assisted living," *Pattern Recognition*, vol. 48, no. 3, pp. 628-641, 2015.
10. D. Singh, E. Merdivan, I. Psychoula, J. Kropf, S. Hanke, M. Geist, A. Holzinger, "Human activity recognition using recurrent neural networks," *International Cross-Domain Conference for Machine Learning and Knowledge Extraction*, pp. 267-274, 2017.